

Hurtownia danych

Martyna Sadowska, Aleksandra Zawadka

Cel biznesowy projektu

Głównym celem biznesowym projektowanej przez nas hurtowni danych jest analiza polskiego rynku nieruchomości w kontekście uwarunkowań makroekonomicznych i demograficznych. System będzie łączył źródła danych instytucji publicznych (NBP, GUS), dostarczając informacji o czynnikach kształtujących ceny mieszkań.

Wdrożenie hurtowni umożliwi odpowiedź na pytania biznesowe oraz realizację następujących celów szczegółowych:

- **Analiza dostępności mieszkań:** Monitorowanie realnej siły nabywczej społeczeństwa poprzez zestawienie średnich cen transakcyjnych za $1m^2$ ze wskaźnikami wynagrodzeń.
- **Analiza kosztów kredytowania:** Śledzenie reakcji rynku nieruchomości (popytu kredytowego oraz ostatecznych cen) na zmiany średniego oprocentowania kredytów.
- **Uwarunkowania rynku deweloperskiego:** Analiza wpływu kosztów produkcji budowlano-montażowej oraz liczby wydawanych pozwoleń na budowę na przyszłą podaż i ceny na rynku pierwotnym.
- **Wsparcie decyzyjne:** Dostarczenie ustrukturyzowanych, ujednoliconych i gotowych do raportowania danych dla analityków, inwestorów oraz deweloperów w celu optymalizacji decyzji biznesowych.

Dane źródłowe

Wskaźniki dynamiki dostępne w części z poniższych danych obejmują stosunek do analogicznego okresu roku poprzedniego, od początku roku do końca okresu, oraz do okresu poprzedniego.

Rynkowa sprzedaż lokali mieszkalnych

Dane pobrane z GUSu z Banku Danych Lokalnych. Jest to 6 tabel zawierających dane kwartalne od 2010 do 2025 roku w podziale na województwa oraz rodzaj rynku (pierwotny i wtórny). Zostaną one przez nas pobrane w formacie CSV. Dostępne są w nich następujące dane na temat sprzedanych lokali mieszkalnych w ramach transakcji rynkowych:

- Liczba,
- Mediana cen za $1m^2$,
- Powierzchnia użytkowa,
- Średnia cena,
- Średnia cena za $1m^2$,
- Wartość.

Przeciętne miesięczne wynagrodzenie

Dane pobrane z GUSu z Banku Danych Makroekonomicznych z zakładki 'Kwartalne', 'Warunki życia ludności'. Tabela, która zostanie przez nas pobrana w formacie CSV zawiera dane kwartalne od 2000 do 2025 roku. Dostępne w niej dane można podzielić na następujące kategorie:

- **Przeciętne miesięczne wynagrodzenie nominalne brutto** (w wartościach bezwzględnych w zł oraz jako wskaźniki dynamiki), w podziale na:
 - gospodarkę narodową,
 - sferę budżetową,
 - sektor przedsiębiorstw,
 - poszczególne sekcje gospodarki (np. przemysł, budownictwo, handel, transport, informacja i komunikacja, obsługa rynku nieruchomości, edukacja, opieka zdrowotna).

- **Przeciętne miesięczne wynagrodzenie realne brutto** (dostępne tylko jako wskaźniki dynamiki):
 - w gospodarce narodowej,
 - w sektorze przedsiębiorstw.
- **Emerytury i renty** (w podziale na system pozarolniczy oraz rolników indywidualnych):
 - przeciętna liczba emerytów i rencistów (w tysiącach osób),
 - przeciętna miesięczna nominalna emerytura i renta brutto (w zł i jako wskaźniki dynamiki),
 - przeciętna miesięczna realna emerytura i renta brutto (jako wskaźniki dynamiki).

Koszty produkcji budowlano-montażowej

Dane pobrane z GUSu z Banku Danych Makroekonomicznych z zakładki 'Kwartalne', 'Budownictwo'. Tabela, która zostanie przez nas pobrana w formacie CSV zawiera dane kwartalne od 2000 do 2025 roku. Dostępne w niej dane można podzielić na następujące kategorie:

- **Sprzedaż produkcji budowlano-montażowej niewyrównana sezonowo w cenach stałych** wyrażona jako wskaźnik dynamiki, w podziale na:
 - wartość ogółem,
 - budowę budynków,
 - budowę obiektów inżynierii lądowej i wodnej,
 - roboty budowlane specjalistyczne.
- **Wskaźniki koniunktury w budownictwie** (odnotowywane w miesiącu kończącym dany okres kwartalny):
 - wskaźnik ogólnego klimatu koniunktury,
 - wskaźnik prognozy ogólnej sytuacji gospodarczej.

Wydane pozwolenia na mieszkania

Dane pobrane z GUSu z Banku Danych Makroekonomicznych z zakładki 'Kwartalne', 'Mieszkania'. Tabela, która zostanie przez nas pobrana w formacie CSV zawiera dane kwartalne od 2000 do 2025 roku. Dostępne w niej dane można podzielić na następujące kategorie:

- **Mieszkania, na których budowę wydano pozwolenia lub dokonano zgłoszenia z projektem budowlanym,**
- **Mieszkania, których budowę rozpoczęto,**
- **Mieszkania w budowie ogółem** (stan na koniec analizowanego okresu),
- **Mieszkania oddane do użytkowania**, w podziale na przeznaczenie:
 - indywidualne,
 - na sprzedaż lub wynajem (deweloperskie),
 - pozostałe.

Statystyka stóp procentowych

Dane zostaną przez nas pobrane ze strony NBP w formacie CSV. Używana przez nas Tabela 4. zawiera średnie oprocentowanie nowych umów w PLN bez umów renegocjowanych w każdym miesiącu od 2014 do 2025 roku. Dostępne w niej dane dotyczące kredytów i innych należności w PLN podzielone są na następujące sektory i kategorie:

- **Gospodarstwa domowe i instytucje niekomercyjne działające na rzecz gospodarstw domowych**, w tym kredyty:
 - na cele konsumpcyjne (bez kredytów o charakterze bieżącym),
 - na nieruchomości mieszkaniowe,
 - pozostałe kredyty i inne należności.
- **Przedsiębiorstwa niefinansowe** ogółem.

Architektura rozwiązania

Diagram przepływu danych:

Źródła danych (CSV) $\xrightarrow{\text{Ekstrakcja}}$ ETL (SSIS) $\xrightarrow{\text{Transformacja/\Ładowanie}}$ Hurtownia Danych (MS SQL) $\xrightarrow{\text{Połączenie}}$ BI (Power BI)

Opis warstw rozwiązania

- **Warstwa źródeł danych:** Pliki w formacie CSV pobrane z Banku Danych Lokalnych GUS, Banku Danych Makroekonomicznych GUS oraz portalu NBP, zawierające surowe dane o rynku nieruchomości i wskaźnikach gospodarczych.
- **Warstwa ETL:** Realizowana za pomocą środowiska SQL Server Integration Services (SSIS), które posłuży do integracji plików źródłowych, ujednolicenia formatów i typów danych, obsługi braków oraz załadowania danych do bazy docelowej. Konieczne będzie ujednolicenie czasu do formatu kwartalnych danych z 2014-2025 oraz usunięcie zbędnych kolumn (takie jak wynagrodzenie realne, emerytury, wskaźniki koniunktury w budownictwie).
- **Warstwa składowania danych:** Hurtownia zaimplementowana w relacyjnej bazie MS SQL Server. Dane zostaną w niej zorganizowane w schemacie galaktyki, zoptymalizowanym pod kątem szybkiego odczytu analitycznego i raportowania.
- **Warstwa prezentacji:** Realizowana przy użyciu Microsoft Power BI, umożliwiając interaktywną eksplorację danych, budowę końcowych dashboardów oraz definiowanie miar i wskaźników analitycznych.