

Hurtownia danych

Zespół Deweloperzy: Martyna Sadowska, Aleksandra Zawadka

Cel biznesowy projektu

Głównym celem biznesowym projektowanej przez nas hurtowni danych jest analiza polskiego rynku nieruchomości w kontekście uwarunkowań makroekonomicznych i demograficznych. System będzie łączył źródła danych instytucji publicznych (NBP, GUS), dostarczając informacji o czynnikach kształtujących ceny mieszkań.

Wdrożenie hurtowni umożliwi odpowiedź na pytania biznesowe oraz realizację następujących celów szczegółowych:

- **Analiza dostępności mieszkań:** Monitorowanie realnej siły nabywczej społeczeństwa poprzez zestawienie średnich cen transakcyjnych za $1m^2$ ze wskaźnikami wynagrodzeń.
- **Analiza kosztów kredytowania:** Śledzenie reakcji rynku nieruchomości (popytu kredytowego oraz ostatecznych cen) na zmiany średniego oprocentowania kredytów.
- **Uwarunkowania rynku deweloperskiego:** Analiza wpływu kosztów produkcji budowlano-montażowej oraz liczby wydawanych pozwoleń na budowę na przyszłą podaż i ceny na rynku pierwotnym.
- **Wsparcie decyzyjne:** Dostarczenie ustrukturyzowanych, ujednoliconych i gotowych do raportowania danych dla analityków, inwestorów oraz deweloperów w celu optymalizacji decyzji biznesowych.

Dane źródłowe

Wskaźniki dynamiki dostępne w części z poniższych danych obejmują stosunek do analogicznego okresu roku poprzedniego, od początku roku do końca okresu, oraz do okresu poprzedniego.

Rynkowa sprzedaż lokali mieszkalnych

Dane pobrane z GUSu z Banku Danych Lokalnych. Jest to 6 tabel zawierających dane kwartalne od 2010 do 2025 roku w podziale na województwa oraz rodzaj rynku (pierwotny i wtórny). Zostaną one przez nas pobrane w formacie CSV. Dostępne są w nich następujące dane na temat sprzedanych lokali mieszkalnych w ramach transakcji rynkowych:

- Liczba,
- Mediana cen za $1m^2$,
- Powierzchnia użytkowa,
- Średnia cena,
- Średnia cena za $1m^2$,
- Wartość.

Przeciętne miesięczne wynagrodzenie

Dane pobrane z GUSu z Banku Danych Makroekonomicznych z zakładki 'Kwartalne', 'Warunki życia ludności'. Tabela, która zostanie przez nas pobrana w formacie CSV zawiera dane kwartalne od 2000 do 2025 roku. Dostępne w niej dane można podzielić na następujące kategorie:

- **Przeciętne miesięczne wynagrodzenie nominalne brutto** (w wartościach bezwzględnych w zł oraz jako wskaźniki dynamiki), w podziale na:
 - gospodarkę narodową,
 - sferę budżetową,
 - sektor przedsiębiorstw,
 - poszczególne sekcje gospodarki (np. przemysł, budownictwo, handel, transport, informacja i komunikacja, obsługa rynku nieruchomości, edukacja, opieka zdrowotna).

- **Przeciętne miesięczne wynagrodzenie realne brutto** (dostępne tylko jako wskaźniki dynamiki):
 - w gospodarce narodowej,
 - w sektorze przedsiębiorstw.
- **Emerytury i renty** (w podziale na system pozarolniczy oraz rolników indywidualnych):
 - przeciętna liczba emerytów i rencistów (w tysiącach osób),
 - przeciętna miesięczna nominalna emerytura i renta brutto (w zł i jako wskaźniki dynamiki),
 - przeciętna miesięczna realna emerytura i renta brutto (jako wskaźniki dynamiki).

Koszty produkcji budowlano-montażowej

Dane pobrane z GUSu z Banku Danych Makroekonomicznych z zakładki 'Kwartalne', 'Budownictwo'. Tabela, która zostanie przez nas pobrana w formacie CSV zawiera dane kwartalne od 2000 do 2025 roku. Dostępne w niej dane można podzielić na następujące kategorie:

- **Sprzedaż produkcji budowlano-montażowej niewyrównana sezonowo w cenach stałych** wyrażona jako wskaźnik dynamiki, w podziale na:
 - wartość ogółem,
 - budowę budynków,
 - budowę obiektów inżynierii lądowej i wodnej,
 - roboty budowlane specjalistyczne.
- **Wskaźniki koniunktury w budownictwie** (odnotowywane w miesiącu kończącym dany okres kwartalny):
 - wskaźnik ogólnego klimatu koniunktury,
 - wskaźnik prognozy ogólnej sytuacji gospodarczej.

Wydane pozwolenia na mieszkania

Dane pobrane z GUSu z Banku Danych Makroekonomicznych z zakładki 'Kwartalne', 'Mieszkania'. Tabela, która zostanie przez nas pobrana w formacie CSV zawiera dane kwartalne od 2000 do 2025 roku. Dostępne w niej dane można podzielić na następujące kategorie:

- **Mieszkania, na których budowę wydano pozwolenia lub dokonano zgłoszenia z projektem budowlanym,**
- **Mieszkania, których budowę rozpoczęto,**
- **Mieszkania w budowie ogółem** (stan na koniec analizowanego okresu),
- **Mieszkania oddane do użytkowania**, w podziale na przeznaczenie:
 - indywidualne,
 - na sprzedaż lub wynajem (deweloperskie),
 - pozostałe.

Statystyka stóp procentowych

Dane zostaną przez nas pobrane ze strony NBP w formacie CSV. Używana przez nas Tabela 4. zawiera średnie oprocentowanie nowych umów w PLN bez umów renegocjowanych w każdym miesiącu od 2014 do 2025 roku. Dostępne w niej dane dotyczące kredytów i innych należności w PLN podzielone są na następujące sektory i kategorie:

- **Gospodarstwa domowe i instytucje niekomercyjne działające na rzecz gospodarstw domowych**, w tym kredyty:
 - na cele konsumpcyjne (bez kredytów o charakterze bieżącym),
 - na nieruchomości mieszkaniowe,
 - pozostałe kredyty i inne należności.
- **Przedsiębiorstwa niefinansowe** ogółem.

Makroregiony

Dane dotyczące podziału terytorialnego zostaną pobrane z klasyfikacji NUTS udostępnianej przez GUS. Pozwolą one na odwzorowanie struktury województw i makroregionów oraz śledzenie zmian w podziale administracyjnym i statystycznym na przestrzeni lat (np. wyodrębnienie makroregionu woj. mazowieckiego w 2018 r.).

Architektura rozwiązania

Diagram przepływu danych:

Źródła danych (CSV) $\xrightarrow{\text{Ekstrakcja}}$ ETL (SSIS) $\xrightarrow{\text{Transformacja/\u0142adowanie}}$ Hurtownia Danych (MS SQL) $\xrightarrow{\text{Po\u0142\u0105czenie}}$ BI (Power BI)


Opis warstw rozwiązania

- **Warstwa \u015bred\u0142 danych:** Pliki w formacie CSV pobrane z Banku Danych Lokalnych GUS, Banku Danych Makroekonomicznych GUS oraz portalu NBP, zawieraj\u0105ce surowe dane o rynku nieruchomości i wska\u017anikach gospodarczych.
- **Warstwa ETL:** Realizowana za pomoc\u0105 \u015brodowiska SQL Server Integration Services (SSIS), kt\u00f3re pos\u0142u\u017cy do integracji plik\u00f3w \u015bred\u0142owych, ujednolicenia format\u00f3w i typ\u00f3w danych, obs\u0142ugi brak\u00f3w oraz za\u0142adowania danych do bazy docelowej. Konieczne b\u0119dzie ujednolicenie czasu do formatu kwartalnych danych z 2014-2025 oraz usuni\u0119cie zb\u0119dnych kolumn (takich jak wynagrodzenie realne, emerytury, wska\u017aniki koniunktury w budownictwie).
- **Warstwa sk\u0142adowania danych:** Hurtownia zaimplementowana w relacyjnej bazie MS SQL Server. Dane zostan\u0105 w niej zorganizowane w schemacie galaktyki, zoptymalizowanym pod k\u0105tem szybkiego odczytu analitycznego i raportowania.
- **Warstwa prezentacji:** Realizowana przy u\u017cyciu Microsoft Power BI, umo\u017cliwiaj\u0105c interaktywn\u0105 eksploracj\u0119 danych, budow\u0119 ko\u0144cowych dashboard\u00f3w oraz definiowanie miar i wska\u017anik\u00f3w analitycznych.

Model hurtowni

Planowana hurtownia danych b\u0119dzie tworzy\u0107 schemat galaktyki widoczny na rysunku 1. Powstanie pi\u0119c tabeli faktowych oraz pi\u0119c tabeli wymiarowych:

- **FaktMieszkania:** Tabela faktowa zawieraj\u0105ca informacje o sprzedanych lokalach mieszkalnych w ramach transakcji rynkowych w danych kwarta\u0142ach.
- **FaktWynagrodzenieRegion:** Tabela faktowa zawieraj\u0105ca informacje o \u015brednim wynagrodzeniu w danym regionie w podziale na kwarta\u0142y.
- **FaktWynagrodzenieSektor:** Tabela faktowa zawieraj\u0105ca informacje o \u015brednim wynagrodzeniu w danym sektorze w podziale na kwarta\u0142y.
- **FaktBudownictwo:** Tabela faktowa zawieraj\u0105ca informacje o budowie mieszka\u0144 oraz cenie sprzeda\u017cy produkcji budowlano-monta\u017cowej.
- **FaktKredytyNieruchomo\u015bci:** Tabela faktowa zawieraj\u0105ca informacje o \u015brednim oprocentowaniu kredyt\u00f3w na nieruchomo\u015bci mieszkaniowe.
- **DimKategoriaMieszkania:** Tabela wymiarowa zawieraj\u0105ca informacje o kategorii mieszkania, kt\u00f3r\u0105 okre\u015blamy po metra\u017cu i rodzaju rynku.
- **DimRegion:** Tabela wymiarowa zawieraj\u0105ca informacje o wojew\u00f3dztwach.
- **DimOkres:** Tabela wymiarowa zawieraj\u0105ca informacje o okresach czasowych.
- **DimSektor:** Tabela wymiarowa zawieraj\u0105ca informacje o sektorach gospodarki.
- **DimJednostka:** Tabela wymiarowa zawieraj\u0105ca informacje o u\u017cytych jednostkach.



Rysunek 1: Schemat galaktyki planowanej hurtowni

Obsługa historyzacji danych (SCD)

W hurtowni zostanie zaimplementowana obsługa zmieniających się wymiarów typu SCD2 dla tabeli **DimRegion**. Tabela ta będzie posiadać atrybuty śledzące historię zmian: datę początkową (**ValidFrom**), datę końcową (**ValidTo**) oraz flagę aktualności rekordu (**ValidFlag**).

Kluczowe miary i atrybuty

Miary bazowe:

- **Dane rynkowe o mieszkaniach:** liczba sprzedanych/oddanych mieszkań, łączna powierzchnia użytkowa, całkowita wartość transakcji, średnia cena mieszkania, średnia cena za m² oraz mediana ceny za m².
- **Zarobki:** kwota przeciętnego miesięcznego wynagrodzenia brutto.
- **Budownictwo:** liczba wydanych pozwoleń na budowę, wartość sprzedaży produkcji budowlano-montażowej.
- **Finansowanie:** stawka oprocentowania kredytów na nieruchomości mieszkaniowe.

Miary wyliczane i wskaźniki KPI:

- **Wskaźnik siły nabywczej:** stosunek przeciętnego wynagrodzenia do średniej ceny za m².

Kluczowe atrybuty:

- **Okresy:** agregacja statystyk z dokładnością do kwartałów i lat.
- **Regiony:** segmentacja danych z podziałem na poszczególne województwa.
- **Rynek/Metraż:** kategoryzacja ze względu na pochodzenie (rynek pierwotny vs. wtórny) oraz przedziały powierzchniowe.
- **Sektory:** podział wynagrodzeń ze względu na sektor gospodarki oraz typ wskaźnika (nominalny/realny).

Planowany proces ETL

Proces ETL zostanie zrealizowany przy użyciu środowiska SQL Server Integration Services. Szczegółowe zasady ładowania danych zostały zawarte w dokumencie STTM.xlsx. Główne kroki i transformacje w procesie zasilania to:

- **Ekstrakcja i oczyszczanie:** Pobieranie danych z płaskich plików CSV. Na tym etapie realizowana jest m.in. zamiana przecinków na kropki w wartościach liczbowych, rzutowanie danych znakowych na odpowiednie typy (`decimal`, `int`) oraz mnożenie wartości podanych w tysiącach.
- **Obsługa braków danych:** Wiersze niekompletne posiadające braki danych będą filtrowane i odrzucane z procesu, aby uniknąć wartości NULL w tabelach faktów.
- **Transformacja UNPIVOT:** Wiele plików źródłowych (m.in. `Stopy_procentowe.xlsx`) przechowuje okresy w nagłówkach kolumn. Komponent UNPIVOT posłuży do transpozycji tych danych do formatu tabelarycznego.
- **Wyznaczanie kluczy obcych:** Naturalne atrybuty tekstowe (np. rok i kwartał z nagłówków) będą mapowane na sztuczne klucze (Surrogate Keys) wygenerowane w tabelach wymiarów (np. `OkresID`, `JednostkaBudownictwaID`, `RegionID`).

Integracja danych: Dane pochodzące z niezależnych źródeł (GUS oraz NBP) zostaną zintegrowane za pomocą wspólnych wymiarów, takich jak `DimOkres` oraz `DimRegion`. Dzięki temu możliwe będzie zestawianie miar z różnych tabel faktów (np. stóp procentowych z liczbą budowanych mieszkań).

Kolejność ładowania danych: Zasilanie będzie przebiegać w następującej sekwencji:

1. Zasilenie oraz aktualizacja tabel wymiarów (w tym `DimRegion` z uwzględnieniem logiki historyzacji SCD2, `DimOkres` oraz `DimJednostka`).
2. Zasilenie tabel faktów (np. `FaktBudownictwo`, `FaktKredytyNieruchomości`). Dzięki wcześniejszemu załadowaniu wymiarów, operacje Lookup w SSIS poprawnie dopasują klucze obce dla wczytywanych faktów.

Orkiestracja i harmonogram zasilania


Docelowo zasilanie hurtowni będzie procesem zautomatyzowanym. Ze względu na fakt, że źródła posiadają różną częstotliwość aktualizacji (dane z NBP publikowane są co miesiąc, a dane z GUS co kwartał), harmonogram zasilania zakłada uruchamianie głównego procesu zasilania raz w miesiącu. Dzięki takiemu podejściu, dane o stopach procentowych będą na bieżąco aktualizowane w hurtowni. Z kolei paczki odpowiedzialne za wskaźniki makroekonomiczne z GUS będą zasilane w cyklach zbiegających się z ich publikacją (w miesiącach kończących dany kwartał statystyczny).

Opis planowanych raportów


W ramach rozwoju systemu BI przewiduje się stworzenie zestawu raportów analitycznych, których zadaniem byłoby badanie korelacji między rynkiem nieruchomości, sytuacją ekonomiczną a sektorem budowlanym. Poniżej przedstawiono przykładowe kierunki analiz, które mogą zostać wdrożone w systemie. Wizualizacja koncepcji jednego z takich zestawień została zaprezentowana na rysunku 2.

- **Analiza siły nabywczej ludności:** zestawienie dynamiki wynagrodzeń z cenami nieruchomości w ujęciu regionalnym.
- **Analiza relacji podaży do poziomu cen:** badanie wpływu liczby nowo oddanych lokali na kształtowanie się średnich cen rynkowych.
- **Badanie wpływu kosztów finansowania na popyt:** zestawienie korelacji między stopami procentowymi kredytów hipotecznych a liczbą lub ceną sprzedawanych mieszkań.
- **Zestawienie kosztów wykonawstwa z cenami ofertowymi:** porównanie sprzedaży materiałów budowlanych z liczbą inwestycji w toku.
- **Prognozowanie dynamiki rynku pierwotnego:** zestawienie liczby wydanych pozwoleń na budowę i sprzedaży produkcji budowlano-montażowej z cenami na rynku pierwotnym.


Analiza rynku mieszkaniowego



Liczba wydanych pozwoleń na budowę



Siła nabywcza w podziale na sektory



Rysunek 2: Przykładowy raport.